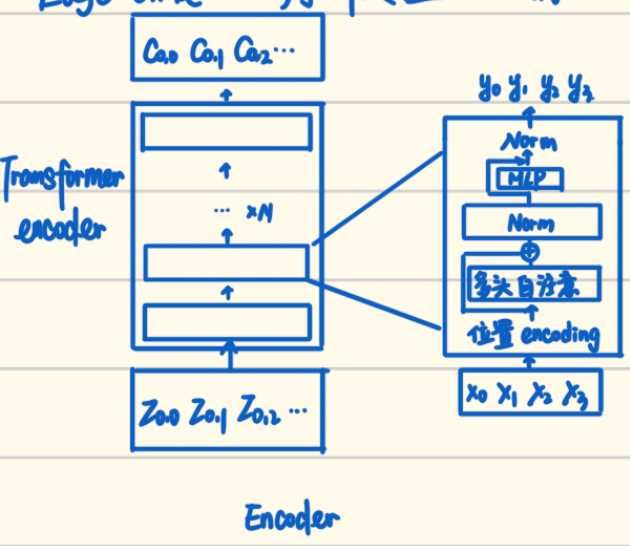
Detection, Segmentation, Visualization and Understanding.

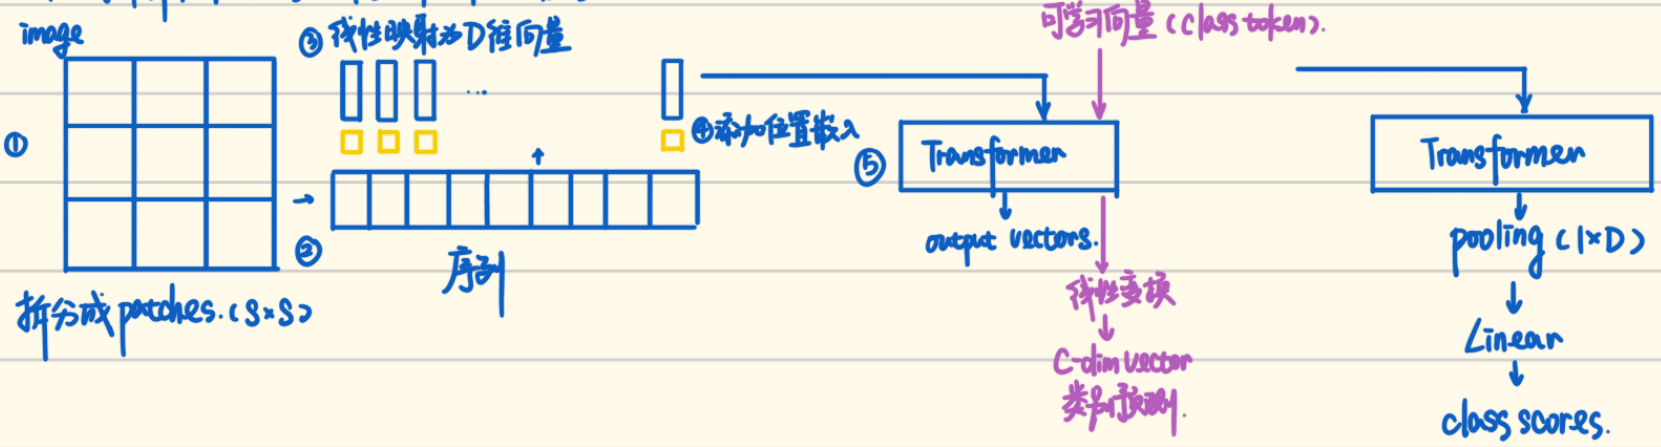
目标检测　图像分割　可视化　理解

Last time: 序列处理: RNN → Transformers.



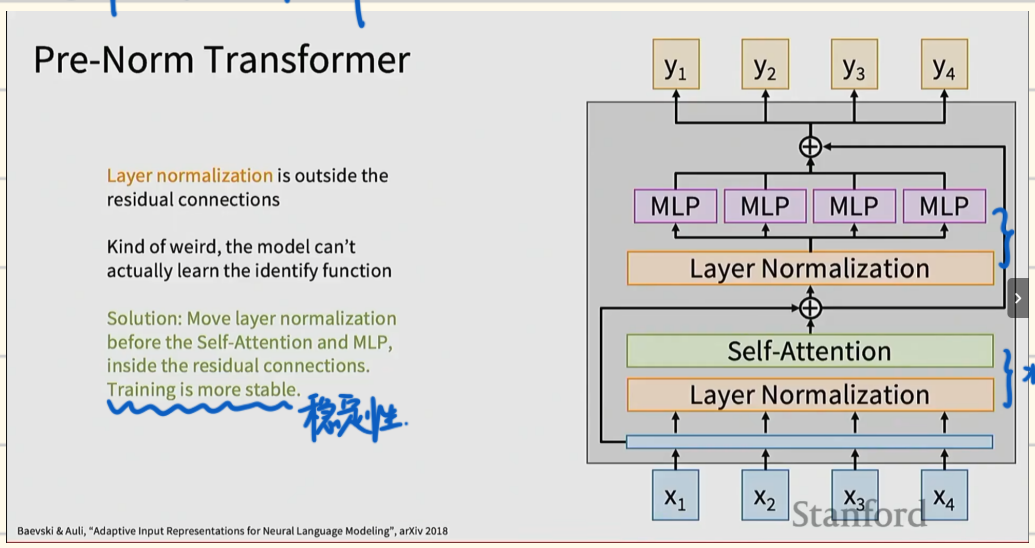
Vision Transformer (ViT).

现代计算机视觉领域使用的核心模型之一.



Transformers 变体:

① pre-Norm Transformer.



② RMSNorm

RMSNorm

Replace Layer Normalization with Root-Mean-Square Normalization (RMSNorm)

Input: x [shape D]
Output: y [shape D]
Weight: γ [shape D]

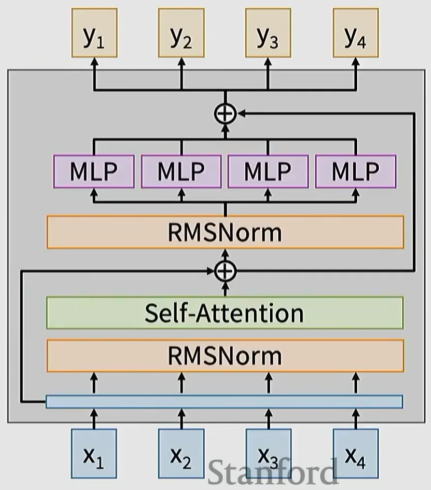
均方根归一化

$$y_i = \frac{x_i}{RMS(x)} * \gamma_i$$

更Stable.

$$RMS(x) = \sqrt{\varepsilon + \frac{1}{N}\sum_{i=1}^{N} x_i^2}$$

Training is a bit more stable



Zhang and Sennrich, "Root Mean Square Layer Normalization", NeurIPS 2019

其他：SwiGLU MLP. MoE …

Today:

- Computer Vision Tasks.
  - Semantic Segmentation
  - Object Detection
  - Instance Segmentation
- Visualization & Understanding.

Semantic Segmentation. 语义分割

为图像内部每个像素打标签.

基本：分类每个像素.
上下文：CNN等 ⇒ 耗时. 需遍历像素.

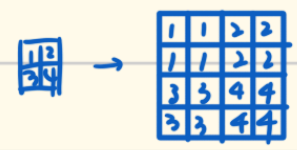
直接输出矩阵. 不能用全连接. 否则同上. 十分耗时.

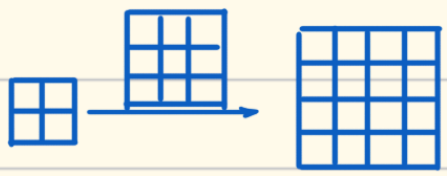
输入图像 → 模型 → 输出像元标签矩阵　FCNN. 全连接卷积网络.

早期GPU无法负担 → 降低分辨率.

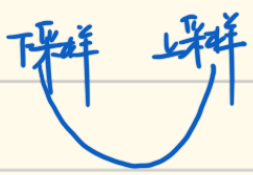
下采样：{pool / Stride conv
上采样：Unpooling
高分辨　低分辨　高分辨

Unpooling：
- Nearest Neighbor.
- Max Unpooling
- Learnable Unsampling.





U-net

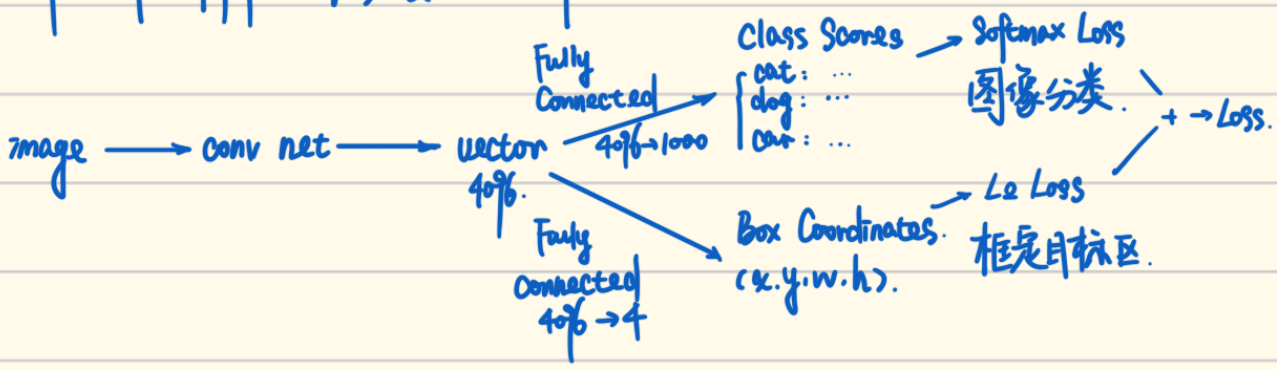


Object Detection ⟶ Instance Segmentation.

计算机视觉的核心任务.

① Object Detection: Single Object

单物体的情形下，任务变为 classfication + Localization.



② 多物体情形：难题在于，当物体数量增长时，其输出坐标也增加 → Region Proposal : Selective Search.

(R-CNN).

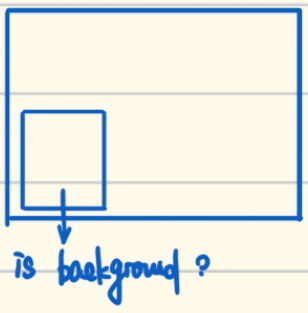
对每个边框内元素分类，判断其类别

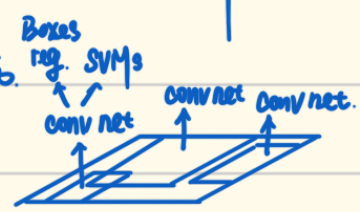
⇓

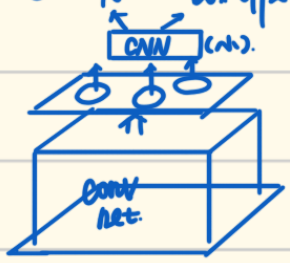
边框进行任性组合，所有可能边框遍历.

选择性地查找可能包含物体的区域.

Problem: 每个 patch 都要过一个 CNN 不并行，慢.





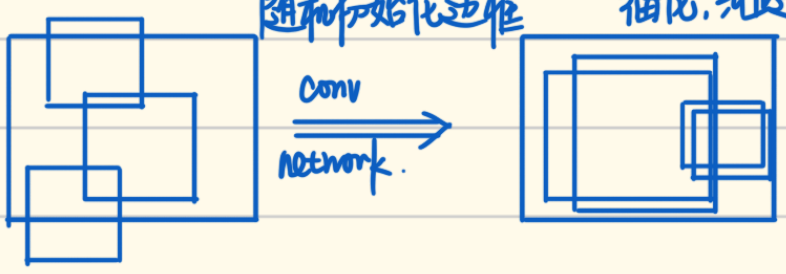


在裁剪前先进行卷积处理.

如何实现区域提案（Region Proposal Network）.

随机初始化边框

细化，纠正边框，确保其中大概率存在物体.



(x,y,h,w, confidence)

置信度.

这种模型的缺陷在于：整个图像需要"区域性提案 + Box 细化.分类"两个网络.

计算量大.

Single-Stage Object Detectors: YOLO / SSD / RetinaNet.

YOLO: (You Only Look Once). 仅通过一次的图像输入，生成所有边界框.

① 将图像分成 S×S 份

⇓

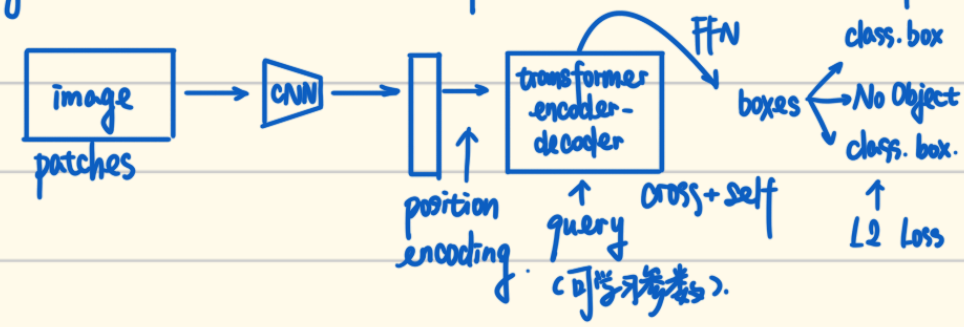
② 对每个网格，执行全卷积网络

- P(object): box包含物体可能性
- B: boxes数量 (x, y, h, w)
- P(class): box内物体属于某类的概率

⇒ ③ 阈值等其他算法

筛选出最有可能的boxes.

Object Detection with Transformers: DETR. 基于Transformers的目标检测.



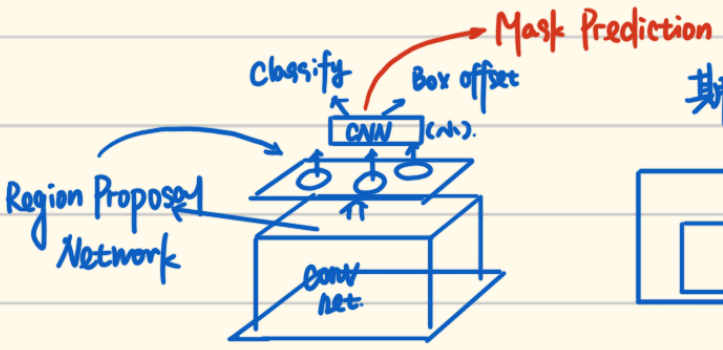
- 直接从Transformer输出一组边界框，无需锚点，无需变换
- 通过二分图匹配，将预测与真实框对齐.

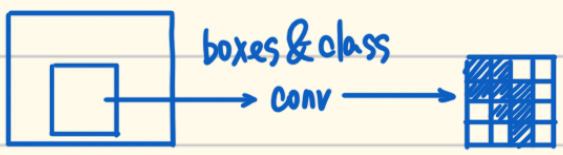
Instance Segmentation:

Mask R-CNN:

额外添加一个输出.

期待其输出一个完全覆盖物体的像素级(or更粗粒度)遮罩.





Recap:

Classfication	Semantic Segmentation	Object Detection.	Instance Segmentation.
直接对整个图像分类	语义分割	物体识别	实例分割
	每像素都需要标签.	在图像上识别多个物体	依据物体识别结果
	无 Objects.	并使用框(boxes)划定	生成对每个物体的遮罩.

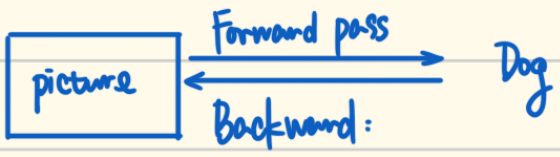
虽然，如今计算机视觉已经足够发达，但理解这些步骤依旧重要.

Visualization & Understanding. 可视化与理解.

可视化神经网络重在理解：网络正在学习的内容.

{ 回到线性分类器的案例. 课堂上展示了其"template"
  在讲卷积神经网络时. 课堂上展示了最底层 filter 的图样. } > 可视化. 视觉观点.

Which pixels matter：通过反向传播实现显著性.

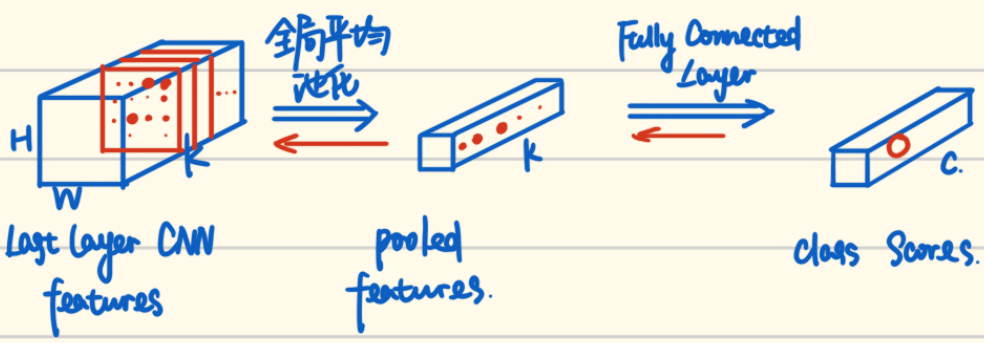


↓

对 picture 的每个 pixel 求偏导. 我们可以得到影响分类（loss）最大的 pixel.

Class Activation Mapping (CAM).

广泛用于CNN的理解与可视化.



依此可以从某类分数开始向前追溯.

一直到原图，得到分数的来源，形成"热力图"

transformer：本身结构含有相关信息.