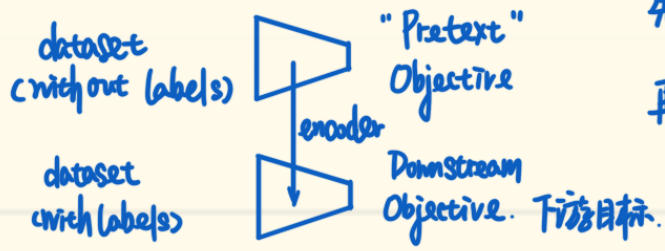
Previous Class: GPUs and How to Train

引入：大规模神经网络的弊端：需要大量标注数据.

是否可能有一种无需人工标注数据的方式来训练

↓

Self-Supervised Learning 自监督学习.

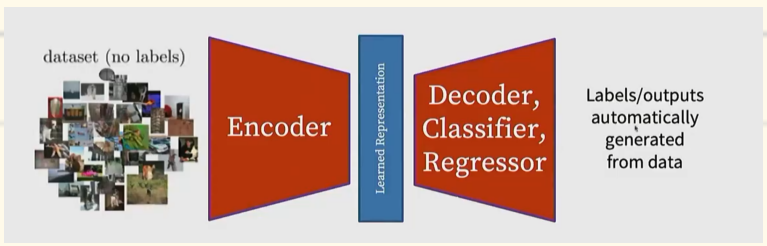


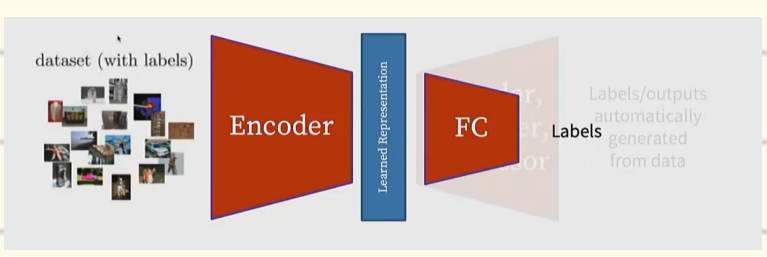
先使用大批量的、无标签数据集得到 "Pretext Objective"

再用带标签的小数据集实现目标（分类等）.

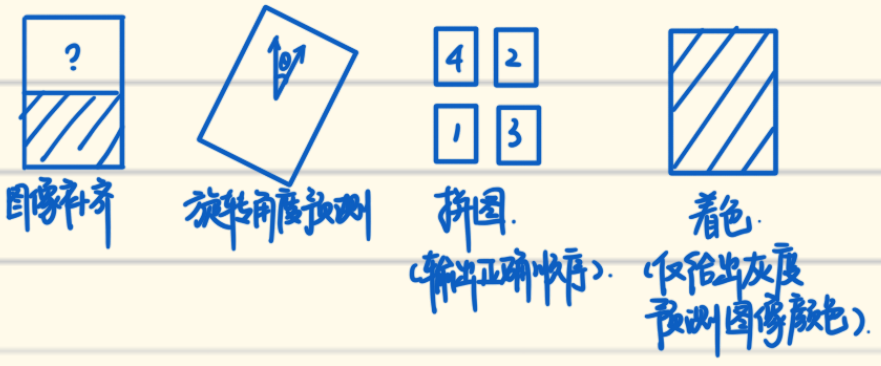
（无标签）.

"Pretext Task". 使模型在数据集上学习到 "good features"





Pretext task 的定义：
① 普遍的
② 可获得良好的特征
③ 无需label（应源于图像自身）.



1. 完成这些 pretext task 有助于模型的 encoder 学习到良好特征

2. 这些 pretext task 可以自动得到标签.

自监督学习方法的评估：

① pretext task 本身的性能.（正确率等）.

② 表示质量评估：对 pretext task 所导致的 encoder 的学习成果的评估.（中间表示）.

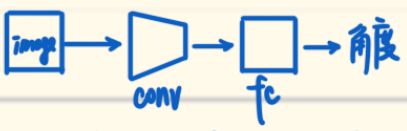
- 线性训练评估：训练一个线性分类器，测试性能.
- 聚类
- t-SNE：降维可视化

...

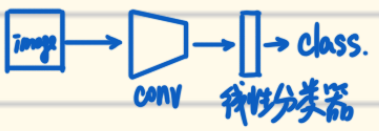
③ 最重要的评估原则：下游表现.

e.g.  大量未标记数据. → self-supervised learning → feature extractor 特征提取器. → supervised learning → 评估目标任务.

 少量标记数据



1. 自监督学习，得到一个优秀的特征提取器. (例如这里的卷积层).



2. 在特征提取器上再连接一个浅层网络.
使用少量标注数据对目标任务浅层训练.

Today's Agenda:

① Pretext tasks from image transformations.
- Rotation 旋转, Inpainting 填充, rearrangement 重排, Coloring 着色
- Reconstruction-based learning (MAE) 基于重建的学习.

② Contrastive representation learning.

Pretext task: predict rotations.

假设：当模型具备"常识"时，它应当能识别正确的旋转角.

(2018年论文). 图像 → CNN → 4类 (0°, 90°, 180°, 270°).

→ 利用此 encoder 训练下游应用
- Freeze conv1 + conv2
- Learn conv3 + 新加入的2个linear layers.

结果：自一开始就从高准确率开始. 最后收敛到与监督训练相似结果.

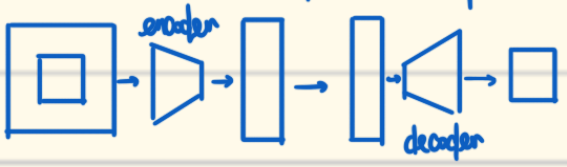
可视化理解：自监督训练的CNN，其注意力将会更多，覆盖更多领域 (在开始并不知道下游任务).

Pretext task: 预测拼图位置.

(2015年论文). 给定中心 patch，尝试给出其它 patch 位置.

(8路分类任务). / 给出一些可能正确的排列，选择正确一次 (例如64路分类). (2016年).

Pretext task: 补全 (预测) 被掩盖的部分.



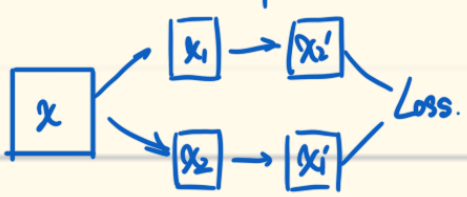
重建损失：计算补丁差异.

详细将在下一节，生成函数中阐述.

pretext task：图像着色

给定灰度，模型尝试给出颜色通道内容.

扩展：

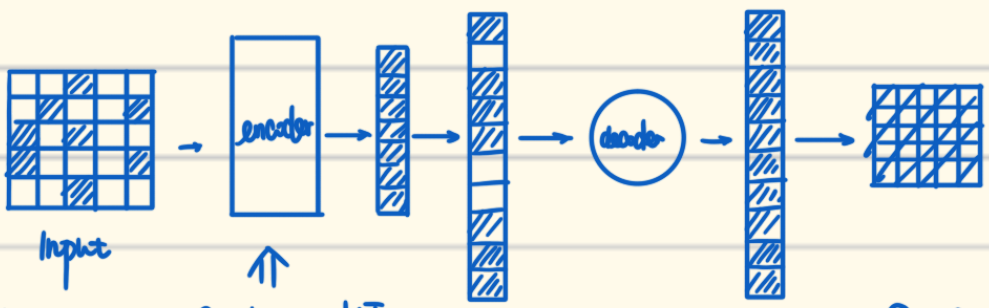


扩展'：为视频中的后几帧上色 → 有助于模型提升跟踪任务.

建立参考帧与目标帧之间的映射关系.

MAE：Masked Auto Encoders (2021).

优秀的预训练框架：带有"更大"遮罩区域的重建



Encoder：

① Similar to ViT.

② 在ViT中均匀选择高比例(75%)的patches进行mask.

③ 高比率的mask使预测困难而有意义.
同时，也意味着同一图像可用于多次训练.

④ encoder仅可见少量patches(25%)
通过线性层嵌入patches，且添加位置信息.

⑤ encoder中使用transformer blocks

⑥ encoder非常大.(9倍于decoder).
(因为仅需处理更少的patches).

Decoder：

① 将encoder输出与shared mask tokens合并并加入位置编码.
shared mask tokens. 共享掩码：让几个空位共享一个向量参数作为待推断的初始状态(可学习).

② 经过几层轻量 Transformer Block，输出重建结果.

③ 用后即弃，训练后不再使用.

Loss：MSE(均方误差损失)

Linear Probing vs. Full Fine-tuning：

线性探测：Encoder不微调，用于预训练质量评估.

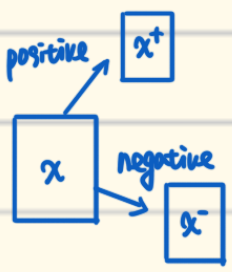
全微调：Encoder的一层，多层接受训练(可能增加新层)，应用于下游任务.

总结：pretext task：

- 利用图像变换
- pretext task 通常关注于普遍的视觉直觉
- 模型通过pretext task 的预训练，学习自然图像的良好特征，并尝试用于下游任务。
- problems：{ 1. 单个的pretext task 太狭隘
  2. 学习的表示、特征可能不普遍。

Contrastive representation learning 对比表征学习。

核心思想：定义"吸引"与"排斥"，以计算图像的关联性。



$\Rightarrow$

我们希望：f: encoder

$score(f(x), f(x^+)) >> score(f(x), f(x^-))$

这样的对比功能有助于模型的通用能力实现。

给定一个评分模型，学习一个编码函数 f，使对于正对 (x, x^+) 分高而 (x, x^-) 分低。

x^+：与 x 相似的，"吸引"物

x^-：不与 x 相似的，"排斥"物

information noise contrastive estimation loss

Loss 定义：InfoNCE loss. 信息噪声对比估计损失。

$$L = -E_X\left[\log \frac{\exp(s(f(x), f(x^+)))}{\exp(s(f(x), f(x^+))) + \sum_{j=1}^{N-1}\exp(s(f(x), f(x_j^-)))}\right]$$

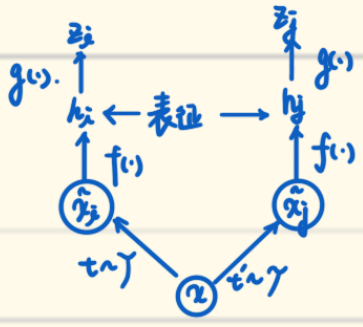
（Softmax 评分）。

正样本评分　　负样本评分。

此 loss 的意义在于提高模型对正对的评分。

SimCLR: A Simple Framework for Contrastive Learning.

利用余弦 $s(u,v) = \frac{u^T v}{\|u\|\|v\|}$ 计算特征相似度。



使用投影 $g(\cdot)$ 将特征映射到对比学习应用空间。

通过数据增强生成正样本：

随机裁剪，随机色彩扭曲，随机模糊。

对大小为 N 的样本 $\{x_k\}_{k=1}^N$：

生成数据增强时 $\tilde{x}_{2k-1}$，$\tilde{x}_{2k}$，$\{\tilde{x}_k\}_{k=1}^{2N}$。

并通过模型得到 z_{2k-1}，z_{2k}，$\{z_k\}_{k=1}^{2N}$

对所有 $i \in \{1, \dots, 2N\}$，$j \in \{1, \dots, 2N\}$：　InfoNCE

$s_{i,j} = \frac{z_i \cdot z_j}{\|z_i\|\|z_j\|}$，令 $loss_{i,j} = -\log \frac{\exp(s_{i,j}/T)}{\sum_{k=1}^{2N} \exp(s_{i,k}/T)}$ $(k \neq i)$。

$\therefore$ 总 Loss $= \frac{1}{2N}\sum_{k=1}^{N}(l(2k-1, 2k), l(2k, 2k-1))$。

Successful: 超越同时代的所有无监督学习，基本生成与监督学习相当的模型.

SimCLR的设计取舍：

投影头（projection head.）

源于合理假设：对比过程会丢失部分信息

通过投影头 h. 有利于使表征空间之保留更多信息.

大批量（large batch size）.

SimCLR需要尽量大的单批数据（N）以获得优秀的学习效果.

（在反向学习中将占用大量内存空间，需要分布式学习）.

↓

MoCo：动量学习. 保留一个动量作为 "queue"

MoCo V2：非线性投影头. 数据增强 → N批量大小下优于SimCLR.