Multi-Model Foundation Models 多模态

回顾：在之前的课程中我们怎么看待 models？

Data Set. → Model → Task.　　针对单一问题，收集数据集，训练特定模型。

⇒ 过去几年的转变：Foundation Model.

- 预训练一个模型，作为多个不同任务的基础。

e.g. GPT with language：

互联网爬取数据 → GPT → {翻译, 提问, ...}

- 优点：使用非常小（甚至不需要）数据以适应新任务。

- Foundation Model 的分类：

Language：{ELMo, BERT, GPT, T5, ...}　Classification (★)：{CLIP, CoCa.}　LM + Vision：{LLaVA, Flamingo, GPT-4V, Gemini.}　And More...　Chaining：{LMs + CLIP, Visual Programming.}

- Foundation 的定义和特征.

- (always)：general / robust to many different tasks.
  通用，坚固

- (often)：- Large params
  - Large training data
  - 自监督预训练.

- Foundation models for classification.

Recall：自监督学习 → 对比学习.

hope：通过此类自监督学习，模型应当有普遍的能力.

- 通过对比学习，使相似的图像更"近"，不同图像更"远"，且仍有将新图像嵌入表征空间的能力
- 这样就能转向分类

↓ 如果将text也加入表征空间中呢？句子.词组...

{ A: "a cute fluffy cat"
B: "My favorate dog is a golden retriever."

-CLIP:

$$\sum_{i=1}^{n} -\log\left(\frac{e^{\langle v_i, v_i\rangle}}{\sum_{j=1}^{n} e^{\langle v_i, v_j\rangle}}\right) + \sum_{j=1}^{n} -\log\left(\frac{e^{\langle v_j, v_j\rangle}}{\sum_{i=1}^{n} e^{\langle v_j, v_i\rangle}}\right)$$

每个图与对应的文最近，
每个文与对应的图最近.

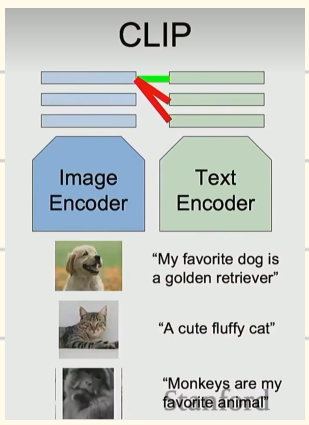

从SimCLR的图→图变为CLIP的图文混合.

- 互联网上拥有大量的图-文联合数据.
- very large scale.

Using pre-trained models out of the box

Step 1: Pretrain a network on a pretext task that doesn't require supervision

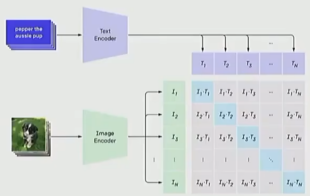

Pre-training tasks: Contrastive Objective

Step 2: Transfer encoder to downstream tasks via linear classifiers

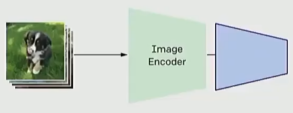

Downstream tasks: Image classification, object detection, semantic segmentation

- 此类超大规模模型的发布使得大量不同任务成为可能.
- CLIP在相同大小的数据集上，效果相当显著.

- Zero-shot：LLMs. 对大语言模型，更大的优势是开箱即用.

Big difference with language models: We can use LLMs zero-shot for new downstream tasks

Step 1: Pretrain a network on a pretext task that doesn't require supervision

"I love ___" → Encoder: ϕ → Decoder: ψ → "cake"

Step 2: Use the model out of the box in a creative way!

"The movie review 'I hated the movie' is ___" → Encoder: ϕ → Decoder: ψ → "negative"

Stanford

Ranjay Krishna

语言模型无需额外下游训练：每个任务都是语言任务.

对CLIP，每次对不同分类任务都需要额外的训练.

↓

- Clever trick：利用text encoder引导模型
  - 在预训练时，图像和文本被嵌入到同一空间下，所以此时text encoder天然有分类能力.
  仅需输入备选词，再与图像向量对比相似度，就能完成分类任务.

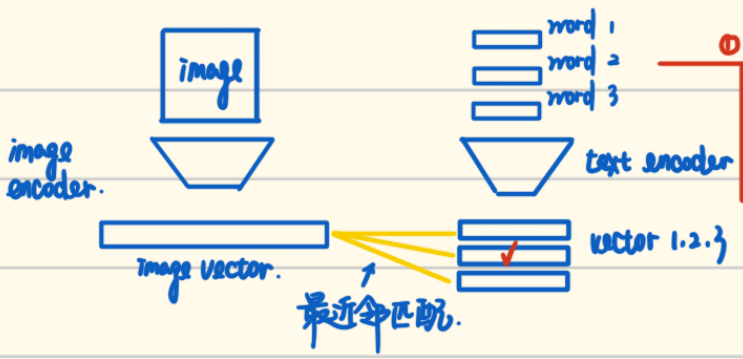

① 由于CLIP用网络上的短语训练，所以用"A photo of..."可以能提高能力.

② 合适的词语选择：A photo of..., A drawing of...
使用它们的平均值，显著提升能力.

- Exciting result after training on 400M image-text pairs.

①

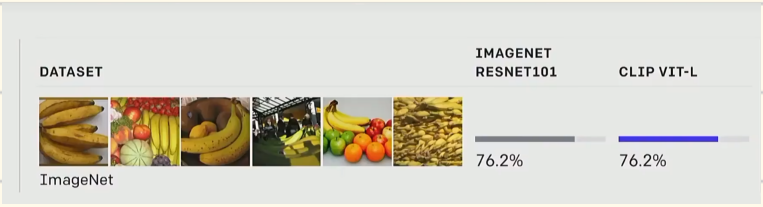

在标准、典型的数据集上（ImageNet）与ResNet一样好
然而CLIP完全没有经过label训练！

②

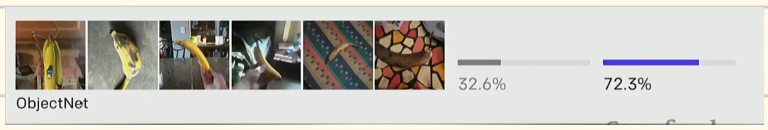

在比较"奇怪"的数据集上，CLIP仍能保有相当高的正确率，
证明其拥有强力的泛化能力.

③ 在我稿，对抗数据集上也有很好的表现.

④ 添加线性头训练前后的性能差距.

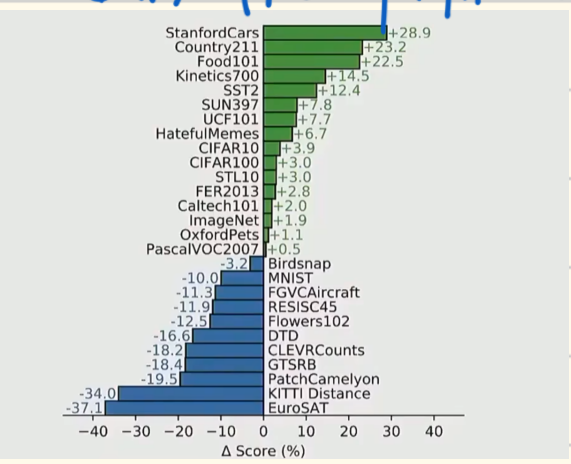

有些数据集上做的更好.
而有些 0-shot 甚至远超线性头

→ CLIP真的具有强大的泛化能力.
被认为是第一个图像基础模型.

可能的原因：① 文本混合训练，其文字包含了更多的结构和信息，提高了自监督学习能力.
② 超大规模的数据量使其泛化能力强化.（4亿图-文对）.
③ CLIP在使用时后，具有远超其他模型的超大参数量（3.0亿）.

- CoCa（2022）.

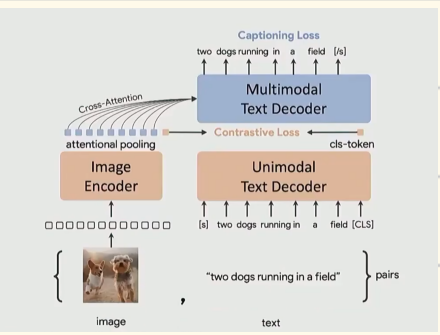

额外添加了一个decoder并计算字幕间的loss（对比学习没变）.
生成字幕需要更多额外信息，利于提升能力.

→ 对比CoCa和CLIP.
性能↑ 10%

- 自此之后，预训练的基础模型打败了我们已知的监督训练模型。

人们只关注用互联网上的数据进行自监督学习。

- CLIP-style 模型的优点：

1. 训练简单，推理极快
2. 开放性词汇描述。
3. 应用广泛，Chain。

- 缺点：

1. CLIP 的对比训练极度依赖 batch size。

但即便如此，也存在上限。某些相近但完全相反的特例即使在上万的 batch size 中也不会出现。（例如"草中间的杯子"和"杯子中的草"）

2. 图像字幕中包含的信息不够。
3. 难以在数据集中找到所有待学习物。（即使有 5B 数据）。

- LLaVA. 视觉-语言基础模型。

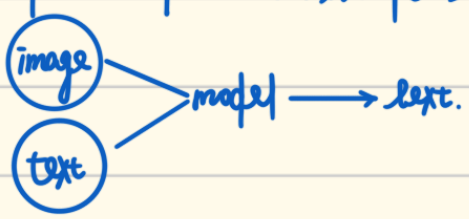

back to 2019: ViLBERT.

通过 text 和 image 联合学习完成跨任务泛化。

回顾：LLMs 的自回归（autoregressive）特性。

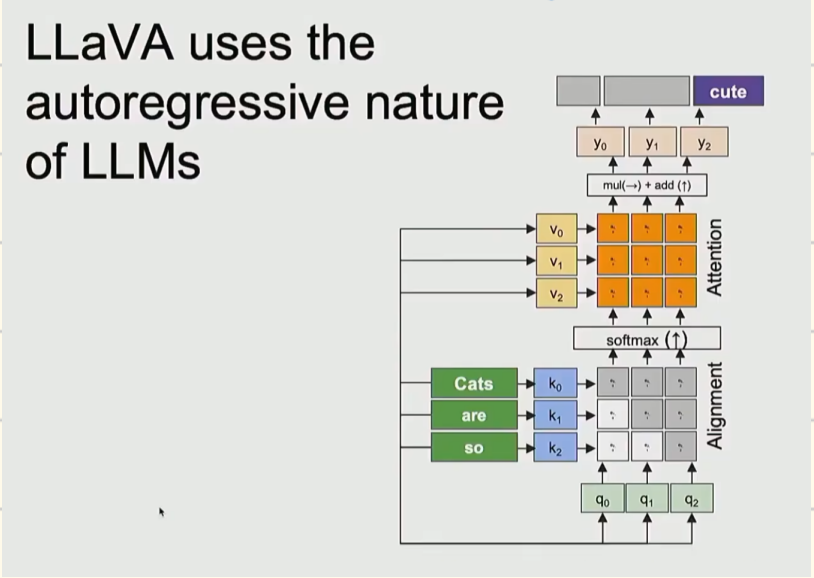

利用带遮罩的 transformer 块，从之前生成的词预测下一个词。

→ Vision language model：将 image tokens 加入上下文。

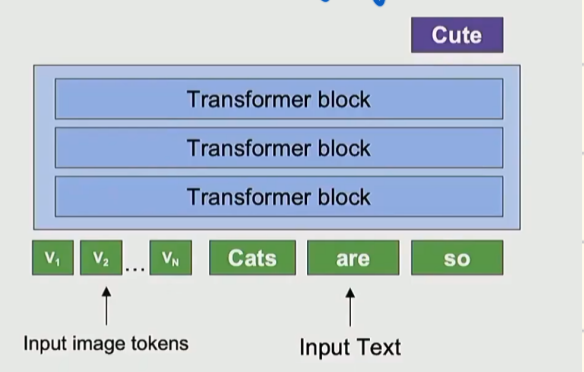

question：image token 应如何定义？

- CLIP encoder:

直接使用CLIP encoder并从中提取特征.

CLIP image encoder内部: ViT

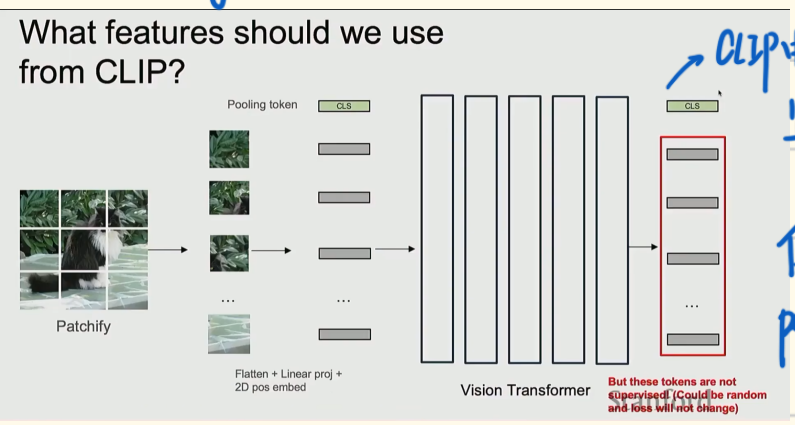

CLIP中,仅用CLS token参与监督学习.(计算loss).

但我们希望利用这些patches对应的token.

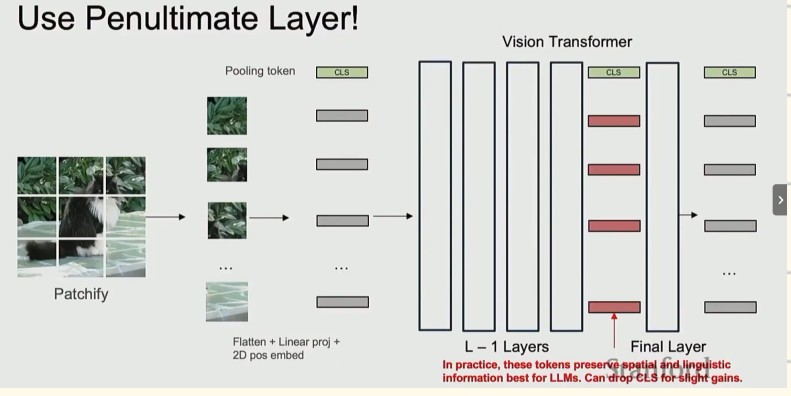

向前倒一层:这些token为CLS带来大量空间信息,语言信息

可将它们作为输入代替CLS以获得更多提升.

- LLaVA: Overall Architecture + Training Recipe.

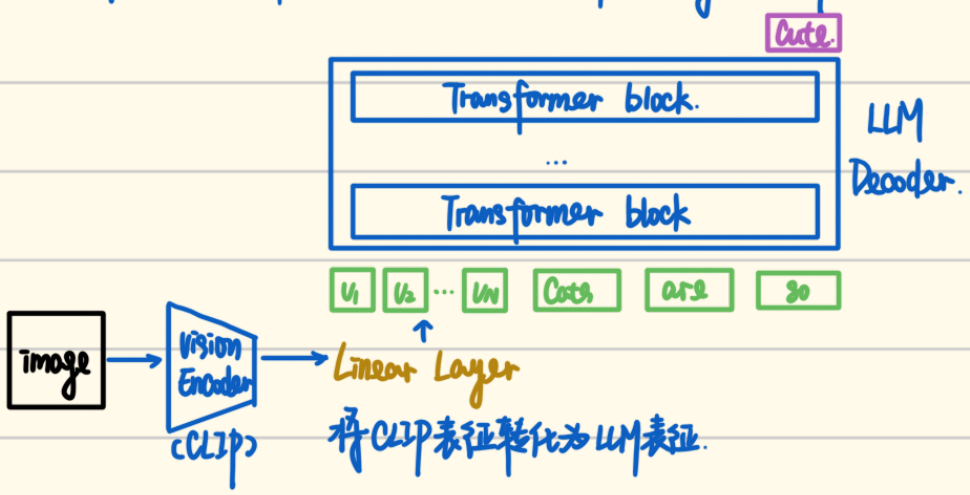

1. 使用预训练的视觉模型和语言模型(如CLIP和LLAMA)初始化.
2. 训练一个线性层来连接两个模型.
3. 联合LLM+Linear,再微调.

- Flamingo: a new way to fuse visual features: cross attention

#lec13.叶中关于VIT的部分正好也对3两类图像/文本信息的嵌入

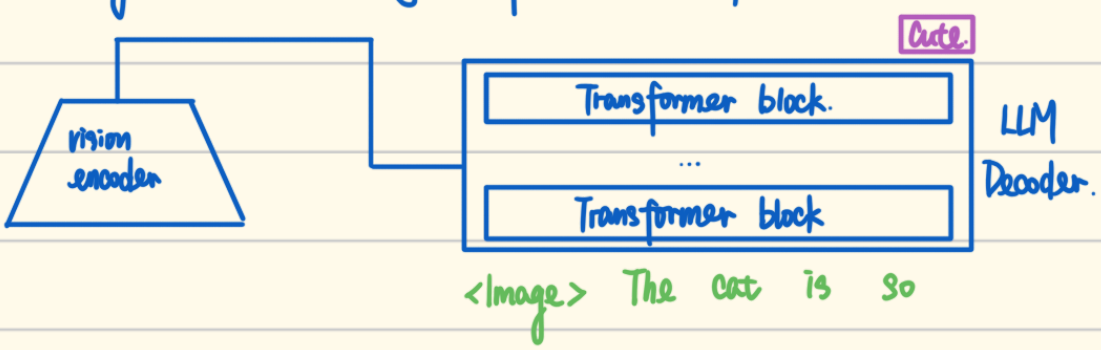

将所有视觉特征输入到每一层.

There are 2 learned parts in Flamingo

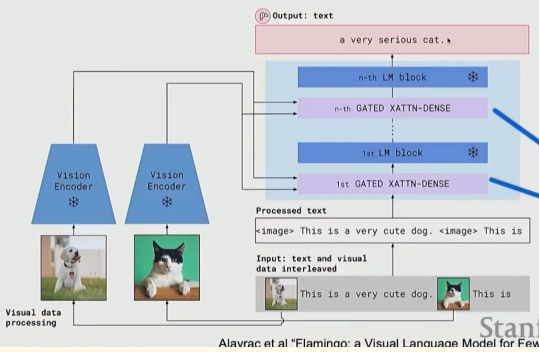

Alayrac et al "Flamingo: a Visual Language Model for Few-Shot Learning, 2022.

① Flamingo 采用图文交替的数据输入. 并在处理时用 <image> 在文本序列中代替它. 输出应该为最后一段图像的描述.

② 在LLM的每一层添加门控交叉注意力.

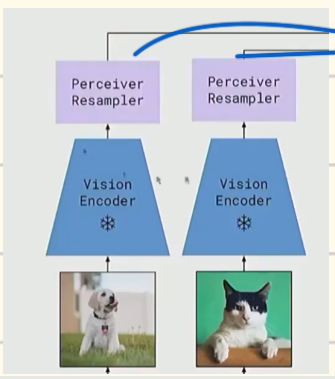

③ 添加感知器采样器. 下采样图像表示.

Flamingo full architecture

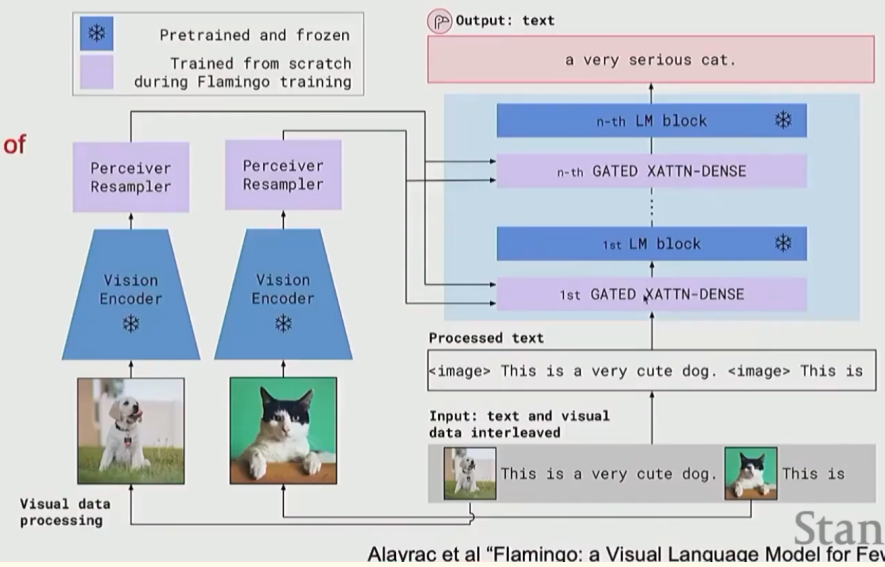

Alayrac et al "Flamingo: a Visual Language Model for Few-Shot Learning, 2022.

LLM组件和 Vision Encoder 都被冻结. 仅学习添加的感知采样层和门控交叉注意层.

Flamingo gated cross-attention

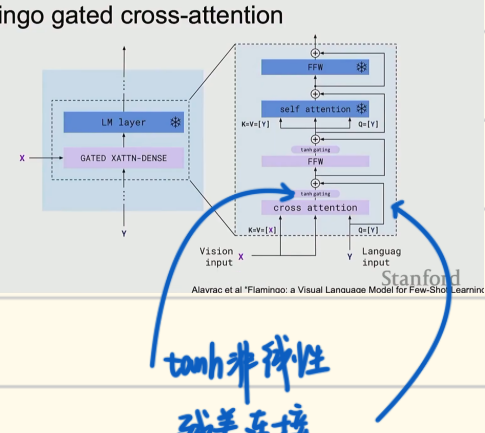

tanh非线性残差连接.

总体来说, cross attention 给予模型什么时候用图像. 什么时候舍去无关部分的能力.

Flamingo masked attention

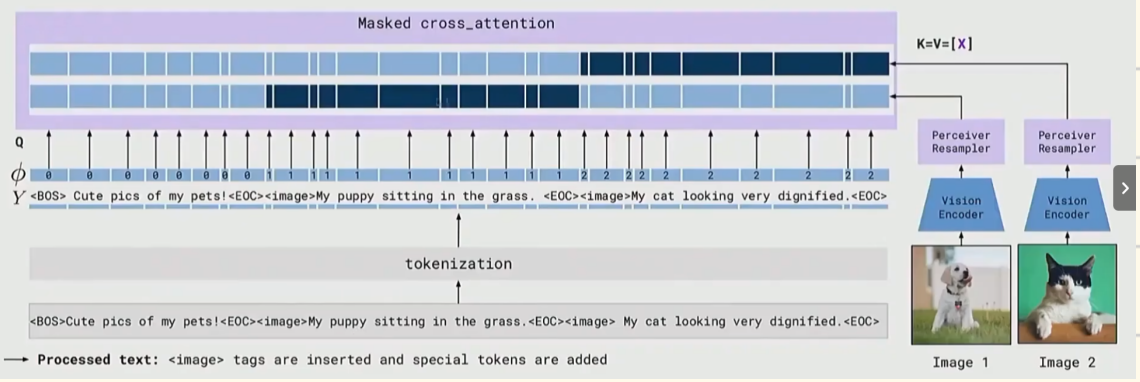

通过 <image>, <EOC> tag 加上交叉注意力的切换, 实现模型在正确的时刻关注正确的图像.

zero-shot 意味着不带上下文. in-context 可以视作 few-shot 学习.

这种文字图像混合输入的目的:

- "对话"式的应用.
- 带上下文的"仿写".

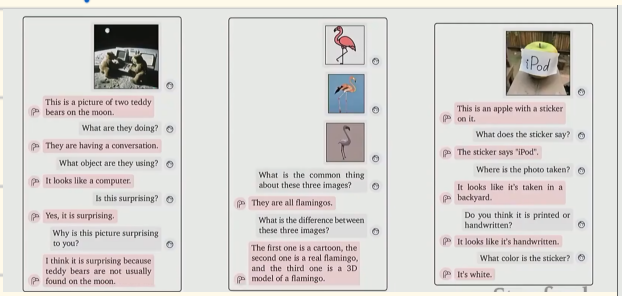

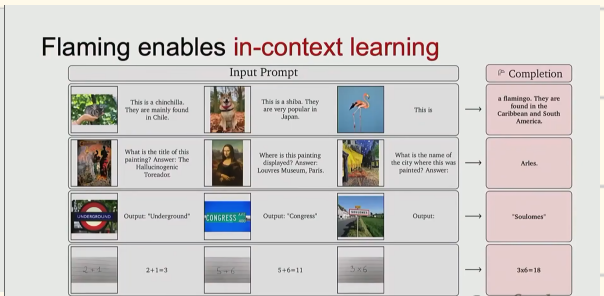

Alayrac et al "Flamingo: a Visual Language Model for Few-Shot Learning, 2022.

Results: zero & few shot

Method	FT	Shot	OKVQA	VQAv2	COCO	MSVDQA	VATEX	VizWiz	Flick30K	MSRVTTQA	iVQA	YouCook2	STAR	VisDial	TextVQA	NextQA	HatefulMemes	RareAct
			[39]	[124]	[134]	[64]				[64]	[145]		[153]	[87]			[94]	[94]
Zero/Few shot SOTA	✗	(X)	43.3 (16)	38.2 (4)	32.2 (0)	35.2 (0)	-	-	-	19.2 (0)	12.2 (0)	-	39.4 (0)	11.6 (0)	-	-	66.1 (0)	40.7 (0)
Flamingo-3B	✗	0	41.2	49.2	73.0	27.5	40.1	28.9	60.6	11.0	32.7	55.8	39.6	46.1	30.1	21.3	53.7	58.4
	✗	4	43.3	53.2	85.0	33.0	50.0	34.0	72.0	14.9	35.7	64.6	41.3	47.3	32.7	22.4	53.6	-
	✗	8	44.6	55.4	90.6	37.0	54.5	38.4	71.7	19.6	36.8	68.0	40.6	47.6	32.4	23.9	54.7	-
	✗	16	45.6	56.7	95.4	40.2	57.1	43.3	73.4	23.4	37.4	73.2	40.1	47.5	31.8	25.2	55.3	-
	✗	32	45.9	57.1	99.0	42.6	59.2	45.5	71.2	25.6	37.7	76.7	41.6	OOC	30.6	26.1	56.3	-
Flamingo-9B	✗	0	44.7	51.8	79.4	30.2	39.5	28.8	61.5	13.7	35.2	55.0	41.8	48.0	31.8	23.0	57.0	57.9
	✗	4	49.3	56.3	93.1	36.2	51.7	34.9	72.6	18.2	37.7	70.8	42.8	50.4	33.6	24.7	62.7	-
	✗	8	50.0	58.0	99.0	40.8	55.2	39.4	73.4	23.9	40.0	75.0	43.4	51.2	33.6	25.8	63.9	-
	✗	16	50.8	59.4	102.2	44.5	58.5	43.0	72.7	27.6	41.5	77.2	42.4	51.3	33.5	27.6	64.5	-
	✗	32	51.0	60.4	106.3	47.2	57.4	44.0	72.8	29.4	40.7	77.3	41.2	OOC	32.6	28.4	63.5	-
Flamingo	✗	0	50.6	56.3	84.3	35.6	46.7	31.6	67.2	17.4	40.7	60.1	39.7	52.0	35.0	26.7	46.4	60.8
	✗	4	57.4	63.1	103.2	41.7	56.0	39.6	75.1	23.9	44.1	74.5	42.4	55.6	36.5	30.8	68.6	-
	✗	8	57.5	65.6	108.8	45.5	60.6	44.8	78.2	27.6	44.8	80.7	42.3	56.4	37.3	32.3	**70.0**	-
	✗	16	57.8	66.8	110.5	48.4	62.8	48.4	**78.9**	30.0	45.2	84.2	41.1	**56.8**	37.6	32.9	**70.0**	-
	✗	32	**57.8**	**67.6**	**113.8**	**52.3**	**65.1**	**49.8**	75.4	**31.0**	**45.3**	**86.8**	42.2	OOC	**37.9**	**33.5**	**70.0**	-
Pretrained FT SOTA	✔	(X)	54.4 [39] (10K)	80.2 [150] (444K)	143.3 [134] (500K)	47.9 [32] (27K)	76.3 [165] (500K)	57.2 [70] (20K)	67.4 [162] (30K)	46.8 [57] (130K)	35.4 [145] (6K)	138.7 [142] (10K)	36.7 [138] (46K)	75.2 [87] (123K)	54.7 [147] (30K)	25.2 [139] (38K)	75.4 [60] (9K)	-

Stanford

Flamingo 的成就是有里程碑意义的：

在众多难度较高的数据集上，Flamingo 在 zero-shot 或 few-shot 的情形下也能取得相当好的效果。

自此以后，计算机视觉领域的模型从报告少量分类基准能力到报告任意类型的理解任务。

（只要把任务化为一个文本输入的问题，就能泛化到各类任务。）

Molmo：比肩顶级闭源（GPT、Claude 等）模型的多模态基础模型。（2024.10）

① Molmo 将决策建立在像素上。

计数问题：易产生幻觉

Molmo：在计数时会"指向"不同像素，决策基于原始像素。

② 少而精的训练数据：

模型在仅 700000 个文本图像对上训练。但这些数据源于人工策划，质量 > 数量。

互联网数据：偶然。对图片具有主观因素，少有图像内容谈论。

PixMo data："故意"：对单个图有详细的描述，并且包含人类不会谈论的视觉世界隐性知识。

（某物在某物左边等。）

③ 制造训练数据：刻意制造的高水平 Questions。高效引出"隐性知识"。

Questions designed to extract meaningful visual information from annotators

- What is the image at first glance?
- What are the objects and their counts?
- What does the text say?
- What are the positions of the objects?
- What subtle details are noticeable?
- What is in the background?
- What is the style and color?

People don't like to type
… but they love to talk

We ask annotators to speak for 60 to 90 seconds about an image

We automatically convert speech into text for pretraining

Stanford

用"talk"更易打破固有印象。

④ 模型架构与 LLaVa 相似。

（image → CLIP → Connector → LLM → text. → loss.）

说明数据的密度与质量有相当高的决定性。

⑤ 从感知到行动："指认"能力带来的"点击"能力.

↓

- 指向"菜单"
- 指向"按钮"
- 指向进度条中段.

更多的... →

- 指向计数
- 图像推理
- ...

⑥ Chaining：将Molmo输出给另一个模型输入.

- 多功能模型，完成多任务
- 自动化. 机器人技术.

- Segment Anything Model (SAM).

- 尝试建构一个"图像分割"任务的基础模型.

- 基于大量类别训练的遮罩模型 ⟶ Problem 1：怎样取得数据？
- 会输出任何用户关心物体的遮罩. ⟶ Problem 2：怎样设计model architecture. 真正确定用户需要？

- Mask.

① 多目标下的重点指向能力.
优秀的遮罩生成.

② Basic SAM Architecture

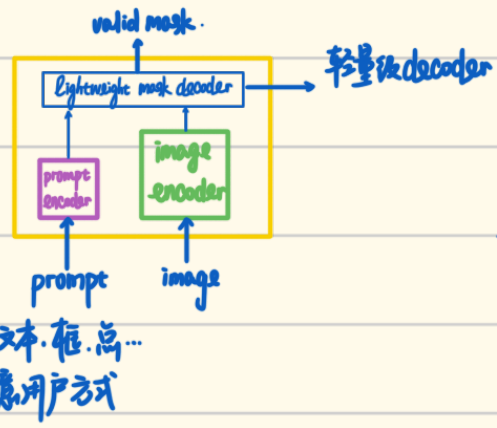

② prompt的"模棱两可"性.

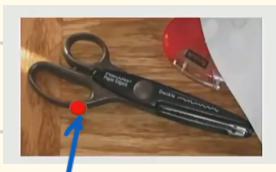

对用户给定的点，可以是柄. 把.
也可以是整个剪刀.

怎样处理此模糊性
并正确应用于loss函数？
(不误导带歧义的生成).

- 一次输出多mask与置信度.
- 使用最接近真实的一个计算loss.

→ 模型将得到多种输出的能力.
- 用户可作选择.

- Data.

SAM收集3大量数据：

相比2023年同期，他们拥有6倍于其他数据集的图像总数
和400倍于其他数据集的分割总数.

高质量数据是让模型取得进步的重要因素.

- Loop process: 循环数据收集.

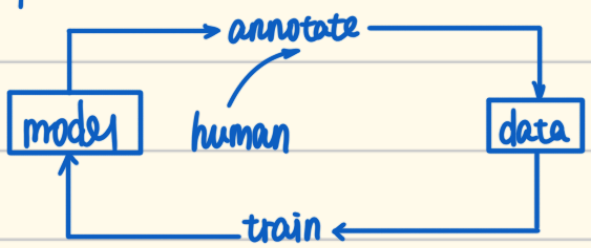

数据集 → 机器学习

↑+

人工修复 ← 机器标注

- 张图片有非常多的 segment.
数据收集相当昂贵.

- Chaining:

-将多个模型结合到一起，以实现单个模型不能完成的事情.

A example: 对"生涩"的类型标签分类.

What happens when a model is asked to classify a concept it has never seen?

A photo of a marimba
A photo of a viaduct
A photo of a papillon
A photo of a lorikeet

-模型从未见过此类词汇，无法分类.

-Solution: 使用chaining:

1. Get an LLM to generate a description.
2. Classify using the description

"A marimba is a large wooden percussion instrument that looks like a xylophone."
"A viaduct is a bridge composed of several spans supported by piers or pillars."
"A papillon is a small, spaniel-type dog with a long, silky coat and fringed ears."
"A lorikeet is a small to medium-sized parrot with a brightly colored plumage."

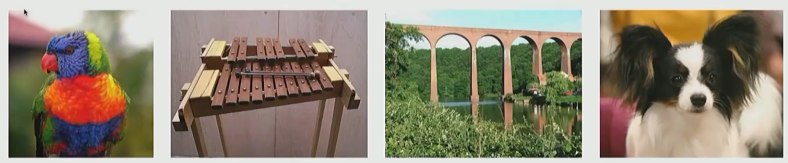

- 使用LLM生成标签释义. description.

- 将标签释义用于分类.

CuPL (CUstomized Prompts via Language models)

	ImageNet	DTD	Stanford Cars	SUN397	Food101	FGVC Aircraft	Oxford Pets	Caltech101	Flowers 102	UCF101	Kinetics-700	RESISC45	CIFAR-10	CIFAR-100	Birdsnap
std	75.54	55.20	77.53	69.31	93.08	32.88	93.33	93.24	78.53	77.45	60.07	71.10	95.59	78.26	50.43
# hw	80	8	8	2	1	2	1	34	1	48	28	18	18	18	1
CuPL (base)	76.19	58.90	76.49	72.74	93.33	36.69	93.37	93.45	78.83	77.74	60.24	68.96	95.81	78.47	51.11
Δ std	+0.65	+3.70	-1.04	+3.43	+0.25	+3.81	+0.04	+0.21	+0.30	+0.29	+0.17	-2.14	+0.22	+0.21	+0.63
# hw	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3

在一些具有"专业类别"的数据集上，
chaining 有更优秀的表现.

- VisProg (visual programming).

Train a new model for your task

output

Multi-image VQA model

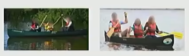

Write a python script with the models you have

```
Class MyMultiImageVQA():

  Def ProcessIms():
    Ans1 = VQA(Image1)
    Ans2 = VQA(Image2)
    Return Ans1 + Ans2
```

General to 2 images now, but not beyond that

根据提问，生成程序，组合答案.

自主调用其他模型.

"Agent".